

Proyecto de Aula. Sistema de agendamiento de citas

INTEGRANTES

Mateo Ossa Restrepo
Documento: 1013456289
Correo: mateo.ossa289@pascualbravo.edu.co

Carlos Andres Ramirez Mejia
Documento: 1000661883
Correo: carlos.ramirez883@pascualbravo.edu.co

Valentina Alvarez Zea
Documento: 1025642484
Correo: valentina.alvarez484@pascualbravo.edu.co


Docente: Jarol Molina Mosquera

Facultad de Ingeniería, Ingeniería En Software.
Institución Universitaria Pascual Bravo.

2. Descripción del sistema.

El sistema es una API de agendamiento de citas médicas. Este sistema permite a los pacientes consultar disponibilidad, agendar, cancelar y reprogramar citas, Estos pacientes son el componente principal y la decisión sería evaluar la capacidad de las citas dependiendo de una franja horaria y una política relacionada con un posible sobrecupo.

El sistema debe cumplir mínimo con esta arquitectura básica.



El paciente solicita una cita → que se pasa al gestor de petición → las peticiones son recibidas y la API ejecuta acciones como consultar disp, crear cita, cancelar cita, reprogramar cita etc. → va a la base de datos y verifica la información → envía a la cola o si hay disponibilidad ejecuta su operación.

En la taxonomía de nuestro sistema se hallaron estas clasificaciones.

- Discreto: Tenemos variables de estado, estas cambian dependiendo de las peticiones que hay en cola y los cupos disponibles.
- Dinámico: Se van a evaluar diferentes tipos de carga y este evalúa el tráfico con su respectiva acumulación de colas a lo largo de una jornada, además de picos de peticiones en diferentes horas que se extenderá en los siguientes puntos.
- Estocástico: Se usarán distribuciones de probabilidad para modelar aleatoriamente tiempos de llegada y latencias de la base.
- Mecanístico: Representamos los recursos internos de nuestro software y así identificar cuellos de botella.

3. problemas y preguntas de decisión.

El sistema de agendamiento de citas médicas presenta un alto rechazo de peticiones durante las horas de mayor demanda. El ingreso masivo de solicitudes de agendamiento, cancelación y reprogramación puede hacer que se acumulen peticiones en la cola, aumentando los tiempos de espera, esto también satura los recursos de la API y supera la capacidad disponible para atender solicitudes. Esto afecta la disponibilidad del servicio para los pacientes. En base a esto, se necesita evaluar

Preguntas de decisión.

- ¿Cuál debe ser el porcentaje máximo de sobrecupo permitido por horario para mantener la tasa de peticiones rechazadas por debajo del 5% durante las horas pico, y qué impacto genera en comparación con la política actual?
- ¿Qué tamaño de cola acumulada se genera al final de la jornada laboral si se restringe el ingreso de peticiones a un máximo de 50 trámites por hora durante los picos de mayor demanda?

- ¿Cómo debe distribuirse de forma óptima la capacidad de atención en el horario entre agendamientos nuevos, cancelaciones y reprogramaciones para **minimizar** la tasa total de rechazos de pacientes y la acumulación de la cola al cierre de la jornada?

4. Objetivos.

Objetivo general

- Analizar a través de este modelo como se comporta un sistema de agendamiento de citas, evaluando diferentes niveles de carga, límites de peticiones con el fin de identificar la forma más óptima la capacidad de atención y mitigar la saturación del sistema.

Objetivos específicos

- Modelar el flujo de las solicitudes de agendamiento, cancelación o reprogramación de citas con sus respectivas restricciones.
- Evaluar el cómo se desempeña el sistema a través de diferentes métricas bajo escenarios tanto de tráfico normal como de horas pico.
- Simular alternativas del control de tráfico de peticiones y un umbral de sobre cupo para determinar la alternativa más óptima que reduzca las peticiones rechazadas a los pacientes

5. Alcance, delimitación y supuestos iniciales.

El sistema se centra en evaluar el comportamiento del sistema de citas en base a diferentes niveles de demanda. Se va a estudiar la capacidad de atención, la acumulación de solicitudes en la cola, la tasa de peticiones rechazadas y aplicar diferentes políticas de sobre cupo y control del tráfico.

¿Qué hace el modelo?

- Llegan solicitudes de los pacientes (Agendamiento, cancelación o reprogramación.)
- Capacidad de atención disponible y distribución entre agendamientos, cancelaciones y reprogramaciones(Son diferentes recursos y por ejemplo puede tener más capacidad de agendamientos que de otro tipo).
- Llegada variable de solicitudes durante la jornada laboral.
- Acumulación de peticiones.
- Límite de trámites por hora.
- Porcentajes de sobre cupo para evaluar su efecto.
- Distribución de capacidad Utilización de recursos
- Tasa de solicitudes rechazadas
- Distingue el factor de utilización entre ambas franjas horarias (horas valle y horas pico) para la distribución y conclusión de recursos.

¿Qué queda fuera del modelo?

- Información detallada de los pacientes, debido a que no es información relevante para nuestro modelo.
- Interfaz gráfica de agendamiento, pues se trabajará con ejecución y simulación de parámetros.
- Costos de recursos empleados, se desea evaluar rendimientos y no el costo que puede tener el mismo.

5.1 Horizonte de simulación

Nuestro modelo simulará una jornada operativa de 8 horas totales, las cuales corresponden a un horario continuo de atención médica contemplado desde las 7:00 am hasta las 3:00 pm.

Trabajaremos en horas como nuestra unidad de tiempo encargada de la medición, por ende las tasas de llegada y de procesamiento se medirán en horas, variando según la demanda horaria que se estipulara en los supuestos.

El estado inicial del sistema será vacío y ocioso, empezando su simulación con 0 peticiones en cola y un tiempo 0 inicial a las 7:00 am (las 0 horas del modelo)

5.2 Tabla de supuestos iniciales.

Supuesto	Justificación	Fuente/evidencia	Impacto.
Jornada laboral de 8 horas	Es la presentación de una jornada usual donde se encuentre habilitada la plataforma	Artículo 161 del código sustantivo del trabajo, como queremos hacer una simulación real de una plataforma habilitada en una franja de 8 horas	Es un desarrollo de las horas unas de ellas horas pico donde es el mayor flujo de peticiones y es algo importantísimo para evaluar
Tasa de llegada horas pico (7:00 AM - 9:00 AM)	En el comienzo de la jornada y en horas de la mañana la simulación enfrentará la mayor cantidad de solicitudes por hora.	Es el comportamiento recurrente en ambientes médicos, pues se busca atender los asuntos de salud lo más pronto posible.	Evaluar la tasa de utilización del sistema en su punto más concurrente, determinando la estabilidad del modelo y sus componentes.
Tasa de llegada horas valle (9:00 AM - 3:00 PM)	Luego de la jornada con mayor concurrencia, (horas más tempranas de la mañana) la simulación estabiliza las solicitudes por hora.	En los ambientes de la salud, luego de las horas de la mañana, cuando se atiende la mayor cantidad de solicitudes, el sistema se estabiliza, dando mayor espacio y tiempo entre trámites.	Comparar las métricas de desempeño y comportamiento del sistema en ambas franjas horarias, determinando cuál sería el estado óptimo del sistema.

Tres tipos de solicitudes	Se desea Agendar, Cancelar o reprogramar, son esos 3 tipos de operaciones las que debe hacer el sistema.	Dentro del problema se identificó esos 3 tipos de acciones que el usuario puede usar	Conocer la cantidad de peticiones para cada distribución, identificando cual es la cantidad más alta y qué recursos requiere
Cola de disciplina FIFO	Las solicitudes que esperan ser atendidas en el orden que llega al sistema.	Este tipo de casos se utiliza la cola fifo para cumplir con que el paciente que entra primero tiene prioridad	Aquí se gestiona todo el tema de colas
Cantidad de servidores	Se debe evaluar cuántos servidores son requeridos para poder gestionar las solicitudes que van llegando	Se debe establecer un límite de servidores que gestionan las solicitudes	Posible cuello de botella sobre todo en horas pico que requiere un alto volumen de peticiones.
La cola de espera tiene capacidad finita $K = 60$; si está llena, la solicitud se rechaza de inmediato	Una API no acumula peticiones sin límite	La cola también debe tener un límite para que en caso de superarlo rechace solicitudes	Conocer cuántas solicitudes son rechazadas y el impacto de evaluar diferentes escenarios.
La mezcla de trámites es constante: agendar con un 60%, cancelar con 15% y reprogramar con 25%	La acción de Agendar es la más predominante por los usuarios, reprogramar es común porque se conserva la cita y cancelar es menos común ya que conservar la cita es la necesidad que desea cubrir el usuario.	En 2024 se hizo un estudio donde 880 pacientes hicieron 1080 interacciones dando como resultado. “(nueva cita 76,8%, reprogramación del 13,1%, cancelación 10,1%) ”, Se ajustaron los parámetros para que sean un poco más distribuido.	Modificar cargas de trabajo en base al desempeño que muestre.
Tiempo procesamiento de cada servidor en procesar una solicitud = 3s	Será el tiempo estimado en el cual se demore en atender cada solicitud.	Los tiempos promedios de respuesta oscilan entre 1.5 y los 5 segundos, se determinan 3 con propósitos de simulación.	Su impacto afecta en cada una de las métricas de desempeño y de utilización del sistema.

6. Modelo Conceptual.

Entidades

La entidad principal es el sistema de solicitud de cita, que representa una petición realizada por un paciente a través de la AP. Cada solicitud tiene sus atributos que permite identificar su tipo, registrar sus tiempos y determinar su resultado.

Tipo	Tipo	atributos
Solicitud de cita	Transitorio, pasa por el proceso	ID, Tipo de trámite, hora de llegada, tiempo de servicio, tiempo de finalización, estado, resultado.
Tipo de trámite	Recurso fijo, solo 3 tipos	Agendamiento, cancelación, reprogramación.

Recursos

Recurso	Capacidad	Funcion
Servidores	4 unidades	procesar solicitudes
Cola de solicitudes	60	Consultar y modificar información de citas

Evento

Evento	¿Qué ocurre?	Variable de estado
Generar peticiones	Aleatoriamente se ejecutan peticiones de forma aleatoria con su tipo	- Tipo de tramite - Estado: iniciado - hora_llegada
Rechazar solicitud	Se encuentra en 2 casos, cuando la cola de peticiones supera su límite y cuando no hay capacidad disponible luego de la consulta	- Tiempo de finalización - estado - Resultado.
Procesar solicitud	La petición entra en procesamiento, en donde se define si es atendida o pasa a cola.	Estado: proceso
Completar solicitud	Si la petición pasa con todos	Estado : completado

	los requerimientos correctamente finaliza su proceso y se genera el agendamiento, cancelación o reprogramación	• tiempo de finalización • resultado
--	--	---

Diagrama de Flujo

 Diagramas- proyecto de aula

7. Análisis analítico preliminar con teoría de colas.

Se selecciona el módulo central de procesamiento de la API, que atiende solicitudes de agendamiento, cancelación y reprogramación.

Se modela como M/M/c:

M: llegadas aleatorias (Poisson).

M: tiempos de servicio exponenciales.

c = 4: servidores concurrentes.

FIFO: las solicitudes se atienden en orden de llegada.

Para las horas pico (7:00–9:00 AM):

Llegadas (λ): 3.600 solicitudes/hora (1 solicitud por segundo).

Servicio: 3 segundos por solicitud.

Tasa de servicio (μ): 1.200 solicitudes/hora por servidor.

Servidores (c): 4.

Cola máxima (K): 60 solicitudes.

Estos valores representan una alta demanda y se basan en los supuestos iniciales de tiempos de respuesta de la AP

Métrica de Desempeño	Símbolo	Fórmula / Relación	Valor Calculado	Unidad / Interpretación

Factor de utilización	ρ	$\lambda/(c \cdot \mu)$	0.75 (75%)	Operación estable pero cercana al umbral de saturación.
Probabilidad de sistema ocioso	P_0	Ecuación de Erlang	0.0377 (3.77%)	Baja probabilidad de encontrar los 4 servidores libres.
Probabilidad de espera (Erlang C)	C	$P(espera)$	0.5094 (50.94%)	Probabilidad de que una nueva solicitud deba hacer fila.
Solicitudes en cola	L_q	$(C \cdot \rho)/(1 - \rho)$	1.53	Promedio de trámites esperando turno de procesamiento.
Tiempo de espera en cola	W_q	L_q/λ	0.000425h ($\approx 1.53s$)	Tiempo que el paciente espera antes de ser atendido.
Solicitudes en el sistema	L	$L_q + (\lambda/\mu)$	4.53	Total de peticiones en cola y en ejecución simultánea.
Tiempo total en el sistema	W	$W_q + (1/\mu)$	0.001258h ($\approx 4.53s$)	Latencia total percibida por la solicitud de la API.

Para las horas valle (9:00 AM–3:00 PM):

Llegadas (λ): 720 solicitudes/hora (0.2 solicitudes por segundo / 1 solicitud cada 5 segundos).

Servicio: 3 segundos por solicitud.

Tasa de servicio (μ): 1.200 solicitudes/hora por servidor.

Servidores (c): 4.

Cola máxima (K): 60 solicitudes.

Estos valores representan una demanda moderada y estable luego del pico matutino, basada en los supuestos iniciales de tiempos de respuesta de la API.

Métrica de Desempeño	Símbolo	Fórmula / Relación	Valor Calculado	Unidad / Interpretación
Factor de utilización	ρ	$\lambda/(c \cdot \mu)$	0.15 (15%)	Operación holgada con alta capacidad ociosa en el backend.
Probabilidad de sistema ocioso	P_0	Ecuación de Erlang	0.5488 (54.88%)	Alta probabilidad de encontrar los 4 servidores completamente libres.
Probabilidad de espera (Erlang C)	C	$P(espera)$	0.0028 (0.28%)	Probabilidad prácticamente nula de que una solicitud deba hacer fila.
Solicitudes en cola	L_q	$(C \cdot \rho)/(1 - \rho)$	0.0005	Promedio de trámites esperando turno (cola inexistente).

Tiempo de espera en cola	W_q	L_q/λ	0.0000007h (0.002s)	Tiempo de espera imperceptible antes de ser procesado.
Solicitudes en el sistema	L	$L_q + (\lambda/\mu)$	0.6005	Promedio de peticiones siendo procesadas en simultáneo.
Tiempo total en el sistema	W	$W_q + (1/\mu)$	0.000834h (3.002s)	Latencia correspondiente casi en su totalidad al tiempo de servicio en BD.

7.1 Limitaciones del Modelo Analítico y Justificación de la Simulación

A pesar de la utilidad del modelo M/M/c, existen supuestos analíticos que no se cumplen en el entorno real, lo que justifica la implementación de una simulación de eventos discretos:

Tasa de llegada no estacionaria (No Poisson homogénea): El modelo analítico asume un flujo de llegadas constante (λ fijo). En realidad, las solicitudes médicas varían drásticamente por horas (picos intensos entre 7:00 AM y 9:00 AM, y caída a horas valle).

Capacidad de cola finita y rechazos dinámicos ($K = 60$): Las fórmulas estándar de M/M/c asumen colas infinitas. Al incorporar un límite estricto de rechazo y políticas de sobrecupo variables por franja horaria, las ecuaciones cerradas analíticas pierden precisión.

Heterogeneidad de trámites: El sistema maneja tres tipos de operaciones con requerimientos y cargas distintas (agendar 60%, cancelar 15%, reprogramar 25%), mientras que el modelo M/M/c tradicional asume un servicio homogéneo indiferenciado.

Transitoriedad vs. Estado Estacionario: La teoría de colas calcula el estado estacionario a largo plazo, pero la gerencia necesita evaluar el comportamiento transitorio y acumulativo al final de una jornada de 8 horas bajo picos de tráfico delimitados.

8. Parámetros, distribuciones y plan de estudios.

Parámetro	Distribución / Modelo	Valores	Fuente
Tasa de llegada (Pico: 7-9 AM)	Poisson / Exponencial	$\lambda = 3.600$ sol/hora (1 sol/s)	Supuestos del sistema y flujos médicos
Tasa de llegada (Valle: 9 AM-3 PM)	Poisson / Exponencial	$\lambda = 720$ sol/hora (0.2 sol/s)	Datos históricos de estabilización
Mezcla de solicitudes	Probabilidad Discreta	• Agendar: 60% • Reprogramar: 25% • Cancelar: 15%	Estudio clínico de interacciones (2024)
Tiempo de servicio (API/BD)	Exponencial / Log-normal	Media $\mu = 3$ segundos	Documentación técnica y pruebas
Servidores (c)	Fijo	$c = 4$ servidores concurrentes	Arquitectura preliminar de la API
Capacidad de cola (K)	Fijo	$K = 60$ solicitudes	Restricción de buffer para evitar saturación
Sobrecupo permitido	Variable de decisión	0%, 5%, 10%	Pregunta de decisión central

8.1 Plan de Recolección de Datos (Entrega 2)

- ¿Qué se medirá?
 1. Latencias de respuesta por tipo de trámite.
 2. Uso de CPU, memoria RAM y pool de conexiones en el backend.
 3. Tasas de llegada empíricas para validar Poisson.
 4. Conteo de peticiones rechazadas por saturación o buffer lleno ($K = 60$).

- ¿Con qué herramientas?
 1. Python principalmente a través del servicio de colab que proporciona google con sus respectivas opciones para probar el sistema.
 2. Github: será el repositorio donde posteriormente se subirá todo el código luego de ser aprobado y ejecutado correctamente.

9. Métricas de desempeño.

9.1 Métricas de Desempeño

- 1. Tasa de Peticiones Rechazadas
 - Cálculo: $(\text{Peticiones rechazadas por buffer lleno} / \text{Total de solicitudes}) \times 100$
 - Umbral: $< 5\%$ en horas pico
 - Pregunta: Responde a la Pregunta 1 y 3 sobre sobrecupo y minimización de rechazos.
- 2. Latencia Percentil 95 (P95)
 - Cálculo: Percentil 95 del tiempo total de respuesta de la API/BD
 - Umbral: ≤ 5.0 segundos
 - Pregunta: Responde a la Pregunta 3 sobre la optimización de capacidad de atención.
- 3. Tamaño Acumulado de Cola (Backlog)
 - Cálculo: Solicitudes pendientes en el buffer ($K = 60$) al finalizar la jornada
 - Umbral: 0 solicitudes (o remanente menor a 5)
 - Pregunta: Responde a la Pregunta 2 sobre acumulación al cierre de la jornada.
- 4. Factor de Utilización del Servidor (ρ)
 - Cálculo: $\lambda_{\text{efectiva}} / (c \cdot \mu)$ con $c = 4$
 - Umbral: 70\% a 85\% en horas pico
 - Pregunta: Responde a la Pregunta 3 sobre la distribución óptima de recursos.

10. Enlace repositorio GitHub

<https://github.com/CarlRM883/Proyecto-aula-CitasMedicas.git>

11. Diseño preliminar de clases.

 Diagrama de clases POO.jpeg

12. Hoja de integración.

Componente	Módulo	Entrega
Desarrollo de la teoría de colas de forma inicial	Se utilizó en investigación de operaciones aunque en esa asignatura se utilizó método simplex	Entrega actual
Diseño del diagrama de clases	Arquitectura de software	Entrega actual
Diseño del sistema en COLAB con lenguaje python	Herramientas de programación	Segundo entregable
Evaluar el comportamiento del sistema en diferentes variables	Pruebas de software	Segundo entregable
Recomendación del docente	Ingeniería en software- enfocar el sistema en base a recomendaciones	Segundo entregable
KPis	Inteligencia de negocios	Entregable final
Desarrollo y entregable final	Ingeniería en software 2	Entregable final

12.1 Riesgos:

Riesgo	Probabilidad	Impacto	plan contingencia
Sesgo en las semillas de simulación: Que los resultados de rechazo y latencia varían fuertemente entre corridas individuales debido a la aleatoriedad de las distribuciones	Alto	Medio	Ejecutar multiples réplicas utilizando diferentes semillas e identificar patrones y así aumentar la confianza del análisis
Desbalance en la distribución del mix de trámites: Que la generación aleatoria discreta (Agendar 60%, Reprogramar 25%, Cancelar 15%) presente desviaciones severas en muestras pequeñas, distorsionando la utilización de recursos	Baja	Medio	Ejecutar un número elevado de solicitudes y réplicas para que la distribución converja a los porcentajes definidos. Verificar estadísticamente la proporción obtenida antes de analizar los resultados.

específicos.			
Saturación de la cola: durante las horas pico la cola puede alcanzar rápidamente el límite establecido de 60 solicitudes, generando un número elevado de rechazos.	Alto	Alto	Evaluar diferentes capacidades de cola, número de servidores y políticas de control de tráfico. Comparar los escenarios
Número insuficiente de servidores: los cuatro servidores definidos inicialmente pueden no ser suficientes para atender la demanda durante las horas pico.	Media	Alta	Simular diferentes cantidades de servidores, por ejemplo 3, 4, 5 y 6, y comparar utilización, latencia, rechazos y tamaño de cola para determinar la capacidad adecuada.

Declaración de uso de inteligencia artificial

Complete una fila por cada uso de IA generativa durante el desarrollo de este examen. Si no usaron ninguna herramienta de IA, dejen la tabla vacía y escriban "No se usó IA" debajo.

Herramienta usada	Parte del trabajo	Instrucción/prompt data	Como se verificó/corrigió
Claude IA	Punto 5	Qué supuestos pueden haber en base a lo presentado en el punto 2-3-4 relacionado con el agendamiento de citas para este sistema que se desea simular, teniendo en cuenta supuesto, justificación, evidencia y impacto	Hay referencias bibliográficas que refutan información relevante como los porcentajes de mezcla en la probabilidad de los 3 tipos de operaciones, además de que se recomienda FIFO como ejemplo en otra referencia porque el usuario que llega es el que primero se atiende
Chat Gpt	Punto 7	Generar un análisis preliminar de la teoría de colas con las 4 secciones de este punto 7 relacionado con el proceso principal de procesamiento de solicitudes, generar los cálculos en tabla.	Se comprobaron los cálculos y estaban correctos, los erróneos se hicieron las respectivas correcciones.
Gemini AI	punto 8	Crear una tabla con los parámetros de entrada solicitados en la primera	Recopila información de los anteriores puntos que se asignaron

		sección del punto 8 relacionado con lo ya realizado en los anteriores 7 puntos	como parámetros para hacer el análisis.
Gemini AI	Punto 9	Generar 4 métricas de desempeño para evaluar el modelo que se ha ido desarrollando durante los 8 puntos realizados dentro del proyecto de aula.	Queremos saber la tasa de peticiones rechazadas, el comportamiento de la API ya
Chat Gpt	Punto 10	Diseñar el diagrama de clases con los puntos más importantes de nuestro proyecto API de generación de citas	Identifica las clases más importantes con sus respectivos métodos y conexiones
Gemini AI	punto 11	En base al proyecto de aula presentado relacionado con la simulación de sistema de citas a través de una API, cuales pueden ser los riesgos de este sistema y cuáles pueden ser sus planes de contingencia	Son riesgos coherentes que definen sobre todo la diferencia entre nuestra simulación y algunos escenarios de la vida real

Gemini AI	Requisito C2	Se empleó inteligencia artificial como herramienta de apoyo y auxilio en trabajo paralelo para el refinamiento de las clases POO y del modelo SimPy.	Se trabajó en paralelo verificando los parámetros establecidos y que el comportamiento y los resultados fuesen los deseados en base a lo planteado.
-----------	--------------	--	---

13. Referencias y anexos.

- Leyes.co. (2026). Código Sustantivo del Trabajo Artículo 161.
https://leyes.co/codigo_sustantivo_del_trabajo/161.htm
- Betancor, P. K., Jordan, J., Boehringer, D., Lüchtenberg, C., Lambeck, M., Ketterer, M. C., Reinhard, T., & Reich, M. (2024). Efficient patient care in the digital age: Online appointment scheduling in an ophthalmology practice. *Digital Health*, 10, 1–11.
<https://doi.org/10.1177/20552076241287083>.
- FasterCapital. (2026). *Teoría de colas: Optimización del servicio al cliente: Aplicación de la teoría de colas y FIFO*.
<https://fastercapital.com/es/contenido/Teoria-de-colas--optimizacion-del-servicio-al-cliente--aplicacion-de-la-teoria-de-colas-y-FIFO.html>
- Cervantes Valdivia, F. S. (2022). Optimización del proceso de gestión de citas y análisis clínicos en un centro de salud.
- Martínez-Gómez, M., & Marí Benlloch, M. D. (2010). La distribución de Poisson.